



南開大學
Nankai University

密码与网络空间安全学院
深度学习及应用（高阶课）实验报告

卷积神经网络算法

姓名：谢小珂

学号：2310422

专业：物联网工程

2026 年 4 月 26 日

目录

1 实验任务、数据设置与总体结果	2
2 卷积神经网络基本原理	2
3 网络结构设计与关键实现	3
4 总体准确率与参数效率分析	5
5 OriginalCNN 与 MicroResNet 曲线分析	6
6 MicroDenseNet 与 MicroMobileNet 曲线分析	6
7 MicroRes2Net 扩展实验与整体收敛趋势	7
8 实验总结与改进方向	8

1 实验任务、数据设置与总体结果

本实验围绕 CIFAR-10 图像分类任务，实现并比较了五种卷积神经网络结构，包括原始 CNN、个人设计的 MicroResNet、MicroDenseNet、基于深度可分离卷积的 MicroMobileNet，以及扩展模型 MicroRes2Net。CIFAR-10 数据集包含 10 个类别，图像尺寸为 $32 \times 32 \times 3$ ，分辨率较低但各类别之间在形状、纹理和背景上存在一定差异，适合用于评估卷积网络在局部特征提取、层级表示和泛化能力方面的表现。

为保证比较的公平性，所有模型采用统一的训练配置：batch size 为 128，训练 120 轮，优化器为 SGD with momentum，权重衰减系数为 5×10^{-4} ，损失函数为带 label smoothing 的交叉熵，学习率采用 5 轮 warm-up 加 cosine decay 的调度方式。训练集用于更新参数，验证集用于选择最佳 checkpoint，测试集仅在最终评估时使用一次，不参与调参，以使测试准确率能够较为客观地反映模型的泛化性能。

模型	参数量	最佳轮数	Best Val	Test	时间	结论定位
OriginalCNN	62,006	115	73.86%	73.99%	15m07s	基础 baseline，用于体现浅层 CNN 的性能上限。
MicroResNet	2,777,674	115	96.34%	95.43%	22m31s	本实验最高精度模型，残差连接优势明显。
MicroDenseNet	910,090	114	95.42%	95.31%	48m55s	参数效率较高，测试精度接近 ResNet。
MicroMobileNet	811,850	117	93.28%	93.26%	19m42s	轻量化结构代表，在精度和计算量之间取得平衡。
MicroRes2Net	644,490	120	94.62%	94.05%	25m02s	多尺度扩展模型，在较少参数下取得较高精度。

表 1: 五个模型的实验结果汇总

表 1 的结果显示，四个改进模型的测试准确率均显著高于 OriginalCNN。MicroResNet 取得了 95.43% 的测试准确率，较 OriginalCNN 提升 21.44 个百分点，增幅最大。MicroDenseNet 的测试准确率为 95.31%，与 MicroResNet 几乎持平，而参数量仅为后者的约 32.8%，表明密集连接在特征复用方面具有较高的参数效率。MicroRes2Net 的参数量低于 MicroMobileNet，测试准确率却高出 0.79 个百分点，说明多尺度结构在参数受限条件下仍然能够有效提升分类性能。

将五个模型放在一起看，性能分布呈现出比较清晰的层次：MicroResNet 与 MicroDenseNet 处于第一梯队，准确率均超过 95%；MicroRes2Net 和 MicroMobileNet 次之，在参数效率和精度之间各有侧重；OriginalCNN 作为浅层基线，准确率明显偏低，反映出结构深度和连接方式对分类性能的决定性影响。这些差异主要来源于网络结构对特征提取方式和梯度传播路径的改进，而非简单的训练轮数叠加。

2 卷积神经网络基本原理

卷积神经网络利用局部连接、权值共享和层级特征提取来处理图像数据。设输入特征图为 X ，卷积核为 W ，第 o 个输出通道在位置 (i, j) 的响应可表示为

$$Y_{o,i,j} = b_o + \sum_{c=1}^{C_{in}} \sum_{u=1}^K \sum_{v=1}^K W_{o,c,u,v} X_{c,i+u,j+v} \quad (1)$$

与全连接层相比，卷积层显著减少了参数量，同时保留了图像的空间结构。卷积核在不同空间位置共享参数，使网络能够识别同一局部模式在不同位置出现的情况，这也是卷积网络适合图像分类任务的重要原因。

在本实验中，OriginalCNN 的输入为 $32 \times 32 \times 3$ 图像，经过两次 5×5 卷积和两次最大池化后，特征图尺寸变为 $16 \times 5 \times 5$ ，因此第一层全连接层输入维度为 400。该维度推导能够验证原始 CNN 的结构实现是否正确。改进模型在此基础上引入 BatchNorm、残差连接、密集连接、深度可分离卷积和多尺度残差分支，从而增强特征表达能力并改善训练稳定性。

分类头输出 logits z ，经 softmax 得到类别概率

$$p_k = \frac{e^{z_k}}{\sum_{c=1}^{10} e^{z_c}}. \quad (2)$$

训练损失采用 label smoothing 交叉熵：

$$\mathcal{L} = - \sum_{k=1}^{10} q_k \log p_k, \quad (3)$$

其中 q_k 为平滑后的标签分布。与普通 one-hot 标签相比，label smoothing 能够降低模型对训练标签的过度置信，使验证集损失曲线更加平稳，也有助于提高泛化能力。

学习率先用 5 轮 warm-up 从较小值逐步升至初始学习率 0.05，随后按照余弦退火方式衰减：

$$\eta_t = \frac{1}{2} \eta_0 \left(1 + \cos \frac{\pi t}{T} \right), \quad (4)$$

其中 $T = 120$ ， $\eta_0 = 0.05$ 。warm-up 可以减少训练初期大梯度造成的不稳定，cosine decay 则使后期学习率逐渐减小，有利于模型在收敛阶段进行细粒度调整。

Listing 1: 统一训练流程中的核心逻辑

```

1 for epoch in range(1, epochs + 1):
2     train_loss, train_acc = train_one_epoch(model, train_loader, criterion,
3                                             optimizer, device, scaler, amp_enabled)
4     val_loss, val_acc = evaluate(model, val_loader, criterion, device)
5     if val_acc > best_val_acc:
6         torch.save({'model': model.state_dict(), 'epoch': epoch}, best_path)
7     scheduler.step()

```

在训练过程中，每一轮结束后均在验证集上评估当前模型，并保存验证准确率最高的 checkpoint。最终测试时载入该 checkpoint 进行评估，而非直接使用最后一轮的权重。这样做的原因是学习率在衰减末期存在一定的随机波动，直接使用最后一轮权重可能无法反映模型的最佳状态。AMP 混合精度用于加速训练，该设置在所有模型上保持一致，不影响比较的公平性。

3 网络结构设计与关键实现

五个模型分别对应了卷积网络发展中的几类设计思路。OriginalCNN 作为浅层基线，用于对照；MicroResNet 加入残差连接以缓解深层网络的优化问题；MicroDenseNet 通过密集连接复用特征；MicroMobileNet 将卷积分解为 depthwise 和 pointwise 两步来降低计算量；MicroRes2Net 则在残差块内部引入多尺度分支，以增强对不同感受野特征的表达能

模型	结构说明
OriginalCNN	由两层卷积、两层最大池化和三层全连接组成，结构简单，但缺少 BatchNorm 和跨层连接。
MicroResNet	stem 后接三个 stage，每个 stage 含 BasicBlock；当尺寸或通道数变化时，用 1×1 shortcut 对齐。
MicroDenseNet	DenseLayer 将新特征与已有特征拼接，TransitionLayer 负责压缩通道并完成下采样。
MicroMobileNet	使用 ‘groups=in_channels’ 实现逐通道卷积，再用 1×1 卷积完成通道混合。
MicroRes2Net	将通道划分为多个尺度分支，后一分支接收前一分支输出，从而在块内形成多尺度表达。

表 2: 模型结构与设计动机对照

以下直接贴出各模型 `print(net)` 的输出结果。重复的 block 较多，为控制篇幅，只保留每层的模块类型、通道数、stride、shortcut、groups 和分类头等关键信息，省略了 eps、momentum 等默认参数。最终指标仍以我自己的输出文件为准。

Listing 2: OriginalCNN 的 `print(net)` 输出

```
OriginalCNN(
  (conv1): Conv2d(3, 6, kernel_size=(5, 5), stride=(1, 1))
  (pool): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  (conv2): Conv2d(6, 16, kernel_size=(5, 5), stride=(1, 1))
  (fc1): Linear(in_features=400, out_features=120, bias=True)
  (fc2): Linear(in_features=120, out_features=84, bias=True)
  (fc3): Linear(in_features=84, out_features=10, bias=True)
)
```

Listing 3: 四个个人实现模型的 `print(net)` 结构输出整理

```
MicroResNet(
  (stem): Sequential(Conv2d(3,64,3,padding=1,bias=False), BatchNorm2d(64), ReLU)
  (stage1): Sequential(
    (0): BasicBlock(residual: Conv3x3 64->64, BN, ReLU, Dropout2d/Identity, Conv3x3 64->64, BN; shortcut: Identity)
    (1): BasicBlock(residual: Conv3x3 64->64, BN, ReLU, Conv3x3 64->64, BN; shortcut: Identity))
  (stage2): Sequential(
    (0): BasicBlock(residual: Conv3x3 64->128, stride=2, BN, ReLU, Conv3x3 128->128, BN; shortcut: Conv1x1 64->128, stride=2, BN)
    (1): BasicBlock(residual: Conv3x3 128->128, BN, ReLU, Conv3x3 128->128, BN; shortcut: Identity))
  (stage3): Sequential(
    (0): BasicBlock(residual: Conv3x3 128->256, stride=2, BN, ReLU, Conv3x3 256->256, BN; shortcut: Conv1x1 128->256, stride=2, BN)
    (1): BasicBlock(residual: Conv3x3 256->256, BN, ReLU, Conv3x3 256->256, BN; shortcut: Identity))
  (pool): AdaptiveAvgPool2d(output_size=(1,1)); (dropout): Dropout(p=0.25); (fc): Linear(256,10)
)

MicroDenseNet(
  (stem): Sequential(Conv2d(3,48,3,padding=1,bias=False), BatchNorm2d(48), ReLU)
  (block1): DenseBlock(6 x DenseLayer, growth_rate=24, channels 48 -> 192)
  (trans1): TransitionLayer(BN192, ReLU, Conv1x1 192->96, AvgPool2d(2))
  (block2): DenseBlock(8 x DenseLayer, growth_rate=24, channels 96 -> 288)
  (trans2): TransitionLayer(BN288, ReLU, Conv1x1 288->144, AvgPool2d(2))
  (block3): DenseBlock(8 x DenseLayer, growth_rate=24, channels 144 -> 336)
  (final): Sequential(BatchNorm2d(336), ReLU, AdaptiveAvgPool2d(1,1)); (dropout): Dropout(p=0.20); (fc): Linear(336,10)
)

MicroMobileNet(
  (features): Sequential(
    (0): ConvBNReLU(Conv2d 3->32, 3x3, stride=1)
    (1): DepthwiseSeparableConv(DW 32 groups=32, stride=1; PW 32->64)
    (2): DepthwiseSeparableConv(DW 64 groups=64, stride=2; PW 64->128)
    (3): DepthwiseSeparableConv(DW 128 groups=128, stride=1; PW 128->128)
    (4): DepthwiseSeparableConv(DW 128 groups=128, stride=2; PW 128->256)
    (5): DepthwiseSeparableConv(DW 256 groups=256, stride=1; PW 256->256)
    (6): DepthwiseSeparableConv(DW 256 groups=256, stride=2; PW 256->512)
    (7): DepthwiseSeparableConv(DW 512 groups=512, stride=1; PW 512->512)
    (8): DepthwiseSeparableConv(DW 512 groups=512, stride=1; PW 512->512)
  )
  (pool): AdaptiveAvgPool2d(output_size=(1,1)); (dropout): Dropout(p=0.20); (fc): Linear(512,10)
)

MicroRes2Net(
  (stem): Sequential(Conv2d(3,64,3,padding=1,bias=False), BatchNorm2d(64), ReLU)
  (stage1): Sequential(2 x Res2Block, 64 channels, stride=1, scale=4, width=16)
  (stage2): Sequential(Res2Block 64->128 stride=2 + Res2Block 128->128 stride=1, scale=4, width=32)
  (stage3): Sequential(Res2Block 128->256 stride=2 + Res2Block 256->256 stride=1, scale=4, width=64)
  Res2Block: conv1=Conv1x1(in->out), split into 4 groups, convs=ModuleList(3 x Conv3x3(width,width)),
    bns=ModuleList(3 x BatchNorm2d(width)), conv3=Conv1x1(out->out), shortcut=Identity/Conv1x1, ReLU
)
```

```
(pool): AdaptiveAvgPool2d(output_size=(1,1)); (dropout): Dropout(p=0.25); (fc): Linear(256,10)
)
```

残差连接可表示为 $y = F(x) + x$ ，使网络学习相对于输入的增量映射，梯度也能沿 shortcut 更稳定地传播。密集连接可写为

$$x_l = H_l([x_0, x_1, \dots, x_{l-1}]), \quad (5)$$

其中 $[,]$ 表示特征拼接，使后续层能够直接访问早期纹理与边缘特征。普通卷积计算量约为 $K^2 C_{in} C_{out}$ ，MobileNet 中的深度可分离卷积将其拆成逐通道空间卷积与 1×1 通道混合，计算量约为 $K^2 C_{in} + C_{in} C_{out}$ ，因此适合轻量化。Res2Net 则把输入划分为 $x_1, x_2, \dots, x_s$ 多个尺度子集，并在相邻分支之间逐级传递：

$$y_i = \begin{cases} K_i(x_i), & i = 1, \\ K_i(x_i + y_{i-1}), & i > 1, \end{cases} \quad y = x + \text{Concat}(y_1, \dots, y_s). \quad (6)$$

这些结构都不是简单堆层数，而是分别改变了梯度传播、特征复用、卷积分解和多尺度表达方式。

4 总体准确率与参数效率分析

图 4.1 展示了五个模型的验证集最佳准确率、测试准确率以及参数量关系。OriginalCNN 与四个改进模型之间存在明显差距，说明浅层卷积网络虽然能够学习边缘、颜色和局部纹理等基本特征，但难以充分建模 CIFAR-10 中更复杂的形状和语义差异。MicroResNet 和 MicroDenseNet 均超过 95%，表明跨层连接对小尺寸图像分类任务具有显著效果。




图 4.1: 五个模型的准确率、参数量与性能关系对比

图 4.1 左侧表明，MicroResNet 的验证集和测试集准确率均最高，是本实验精度表现最好的模型。MicroDenseNet 的测试准确率仅比 MicroResNet 低 0.12 个百分点，但参数量明显更少，说明密集连接在特征复用方面具有优势。MicroRes2Net 的测试准确率为 94.05%，高于 MicroMobileNet 的 93.26%，同时参数量更低，表明多尺度残差分支在较小参数规模下仍能提升分类能力。

图 4.1 右侧进一步展示了参数量与测试准确率之间的关系。MicroResNet 位于高精度区域，但参数量最大；MicroDenseNet 在较少参数下取得接近 ResNet 的性能，体现了较高的参数利用效率；相比之下，OriginalCNN 参数量虽然最少，但准确率明显较低，表明单纯减少参数并不等同于高效结构，合理的连接方式和特征组织方式更加关键。

5 OriginalCNN 与 MicroResNet 曲线分析

OriginalCNN 最终测试准确率为 73.99%。该模型为浅层结构，卷积层数量有限，主要学习低层纹理和边缘特征，对类别间复杂差异的表达力不足。后期验证准确率提升幅度逐渐减小，说明性能瓶颈来自结构容量，而非训练轮数不足。

MicroResNet 的测试准确率达到 95.43%，是本实验最高结果。其训练前期收敛速度较快，说明残差连接和 BatchNorm 有助于稳定优化过程；训练后期在 cosine 学习率衰减作用下继续微调分类边界，使验证准确率进一步提高。与 OriginalCNN 相比，MicroResNet 不仅更深，而且通过 shortcut 改善梯度传播，使深层特征能够被有效学习。




图 5.2: OriginalCNN 与 MicroResNet 的 loss/accuracy 曲线对比

图 5.2 中，OriginalCNN 的 loss 下降速度较慢，验证准确率平台较低，体现出浅层网络表达能力有限。MicroResNet 的验证准确率在训练早期快速提升，并在后期保持稳定增长，最终达到 96.34% 的最佳验证准确率。两组曲线说明，在 CIFAR-10 分类任务中，仅增加训练轮数并不能弥补结构表达能力的不足；相比之下，合理的残差路径和深层特征提取能力对性能提升更为关键。

6 MicroDenseNet 与 MicroMobileNet 曲线分析

MicroDenseNet 的测试准确率为 95.31%，与 MicroResNet 十分接近，但参数量明显更少。DenseBlock 中每一层都会将新生成的特征与已有特征进行拼接，使后续层能够直接利用浅层边缘信息、中层纹理信息和高层语义信息。对于 CIFAR-10 这类小尺寸图像，浅层细节对分类仍然具有重要作用，因此 DenseNet 的特征复用机制能够带来较明显的性能提升。

MicroMobileNet 的测试准确率为 93.26%，低于 MicroDenseNet，但训练时间更短，参数量也保持在较低水平。该模型使用深度可分离卷积，将空间卷积和通道混合分开处理，从而减少普通卷积中的冗余计算。其局限在于通道间信息交互主要依赖 1×1 pointwise 卷积，表达能力相对弱于 ResNet 和 DenseNet 这类跨层连接更充分的结构。




图 6.3: MicroDenseNet 与 MicroMobileNet 的 loss/accuracy 曲线对比

图 6.3 显示, MicroDenseNet 的验证准确率在训练后期仍能持续提升, 最佳验证准确率出现在第 114 轮, 说明密集连接有助于稳定利用不同层级特征。MicroMobileNet 的训练过程整体平稳, 验证准确率最终达到 93.28%, 但其平台区间低于 DenseNet, 说明轻量化卷积结构在降低计算量的同时也牺牲了一部分表达能力。

从训练曲线看, DenseNet 强调特征复用和准确率, MobileNet 强调计算分解和轻量化, 二者均显著优于 OriginalCNN。

7 MicroRes2Net 扩展实验与整体收敛趋势

MicroRes2Net 是本实验中的扩展模型。它保留 ResNet 的 shortcut, 同时在残差块内部将通道划分为多个 scale, 使不同尺度分支之间形成逐级信息传递。其核心思想可概括为

$$y = x + \text{Concat}(y_1, y_2, \dots, y_s), \quad y_i = K_i(x_i + y_{i-1}). \quad (7)$$

这种设计使单个残差块内部就能够获得多级感受野, 不需要单纯依赖增加网络深度来扩大表达范围。




图 7.4: MicroRes2Net 的训练损失、验证损失与准确率变化曲线

图 7.4 显示, MicroRes2Net 的训练准确率和验证准确率整体呈稳定上升趋势, 验证损失在后期持续下降, 说明多尺度残差分支能够有效提升模型对不同粒度视觉特征的建模能力。该模型的最佳验证准确率为 94.62%, 测试准确率为 94.05%, 参数量为 644,490。虽然 MicroRes2Net 没有超过 MicroResNet 和 MicroDenseNet, 但它在参数量低于 MicroMobileNet 的情况下取得更高测试准确率, 证明多尺度结构在参数受限条件下具有实际价值。

与其他模型相比, MicroRes2Net 的优势在于: 它不像普通 ResNet 那样主要依靠加深 stage 扩大感受野, 而是在 block 内部构建多尺度特征; 它也不像 DenseNet 那样持续拼接所有历史特征, 因此参数规模和特征组织方式更加紧凑。其不足在于分支划分、尺度连接和通道拼接增加了实现复杂度, 且 scale 数量和通道宽度等超参数会影响最终效果。本实验中 MicroRes2Net 作为扩展模型体现了结构创新性, 也为后续优化提供了进一步空间。




图 7.5: 五个模型在验证集上的准确率变化趋势

图 7.5 汇总了五个模型在验证集上的准确率变化。OriginalCNN 始终处于较低准确率区间，而四个改进模型在训练早期便明显拉开差距。MicroResNet 和 MicroDenseNet 后期稳定处于第一梯队，MicroRes2Net 与 MicroMobileNet 位于第二梯队，但仍远高于 baseline。整体趋势与最终测试结果一致，说明模型性能差异并非由单次测试随机波动造成，而是在完整训练过程中逐渐形成的结构优势。

从最佳轮数看，多数模型的最优验证结果出现在训练末期附近，说明 120 轮训练已基本充分；MicroRes2Net 在第 120 轮最佳，后续仍可能有小幅提升空间。

8 实验总结与改进方向

本实验实现并比较了五类卷积神经网络。OriginalCNN 作为 baseline 测试准确率 73.99%；MicroResNet 最高 95.43%；MicroDenseNet 以更少参数达 95.31%；MicroMobileNet 为 93.26%；MicroRes2Net 为 94.05%。这些结果验证了残差连接、密集连接、深度可分离卷积和多尺度残差分支在 CIFAR-10 图像分类任务中的作用。

模型	主要优势	主要局限	结构作用
OriginalCNN	结构简单、训练速度快	表达能力不足，准确率上限较低	作为 baseline 体现改进必要性。
MicroResNet	精度最高，收敛过程稳定	参数量最大	通过 shortcut 改善深层网络优化。
MicroDenseNet	参数效率高，精度接近 ResNet	特征拼接带来一定训练开销	通过密集连接实现特征复用。
MicroMobileNet	结构轻量，训练时间较短	准确率略低于第一梯队	通过 depthwise/pointwise 分解降低计算量。
MicroRes2Net	参数量少，多尺度表达能力较强	实现复杂度较高	在残差块内部构建多级感受野。

表 3: 五个模型的优点、局限与结构作用

从结果上看，ResNet 和 DenseNet 的跨层连接在小尺寸图像分类中效果明显，二者准确率均超过 95%。MobileNet 侧重于通过深度可分离卷积降低计算量，Res2Net 则是在残差块内部做多尺度特征提取，二者在参数效率和精度上各有侧重。

实现方面有两个问题值得注意。验证阶段需要切换到 eval() 模式并关闭梯度计算，否则 BatchNorm 和 Dropout 会带来额外波动；模型选择应依据验证集上的最佳 checkpoint，而不是直接使用最后一轮权重。本实验采用前者，测试结果相对稳定。

后续还可以从几个方向继续深入：尝试更强的数据增强方法，统计 FLOPs 和推理延迟来量化轻量化的收益，以及调整 Res2Net 的 scale 参数和通道宽度分析多尺度分支的影响。

归结起来，五个模型对应了卷积网络中几种不同的设计思路：shortcut 改善梯度传播，密集连接强化特征复用，深度可分离卷积降低计算量，多尺度分支增强感受野。从对比中可以看出，结构设计对分类性能的影响比单纯增加网络深度更为关键。